

Introducere

Rata de renunțare a clienților (customer churn) descrie situația în care clienții decid să își închidă conturile și să întrerupă colaborarea cu banca,. Pentru orice instituție financiară, minimizarea acestui fenomen este absolut critică. Pierderea clienților afectează direct profitabilitatea băncii, iar costurile asociate cu atragerea de noi clienți sunt, de regulă, mult mai mari decât cele necesare pentru retenția clienților existenți. Prin urmare, transformarea datelor în informații utile pentru a preveni aceste plecări reprezintă o prioritate strategică.

Pentru a aborda această problemă, analiza se bazează pe setul de date Churn_Modelling, care conține detalii specifice despre portofoliul de clienți al băncii. Acest set de date ne oferă o imagine de ansamblu cuprinzătoare, incluzând următoarele tipuri de variabile:

- **Variabile demografice:** vârsta (Age), genul (Gender) și țara de proveniență (Geography)
- **Variabile financiare și comportamentale:** scorul de credit (CreditScore), soldul contului (Balance), salariul estimat (EstimatedSalary), vechimea relației cu banca (Tenure), numărul de produse utilizate (NumOfProducts), deținerea unui card de credit (HasCrCard) și statutul de membru activ (IsActiveMember)

Punctul central al analizei noastre este variabila țintă denumită Exited. Aceasta este o **variabilă binară**, unde valoarea 1 indică faptul că un client și-a închis contul (client pierdut), iar valoarea 0 indică faptul că acesta a fost reținut.

Obiectivul principal al acestui raport este de a înțelege tendințele de comportament care îi determină pe clienți să renunțe la serviciile băncii și de a construi un model predictiv robust. Astfel, prin luarea deciziilor bazate pe date, vom putea prognoza ce categorii de clienți prezintă un risc crescut de plecare și vom oferi conducerii băncii recomandări pentru a implementa strategii eficiente de retenție.

Analiză descriptivă

1. Prezentarea Generală a Bazei de Clienți

10K

Count of CustomerId

2K

Sum of Exited

20.37%

Average of Exited

Count of CustomerId by Exited




Figura 1: Proporția clienților care au părăsit banca (Churn Rate) comparativ cu cei reținuți

Graficul de tip "pie chart" evidențiază un dezechilibru al claselor :

- **Segmentul bleu deschis (79,63%):** Reprezintă majoritatea bazei de clienți (aproximativ 7.960 de persoane) care nu au renunțat la serviciile companiei.
- **Segmentul bleu închis (20,37%):** Reprezintă segmentul de clienți pierduți (aproximativ 2.040 de persoane).

Această rată de pierdere de peste 20% reprezintă o problemă semnificativă de retenție pentru bancă, justificând necesitatea investigării aprofundate a factorilor care determină aceste plecări.

2. Profilul Demografic al Clienților Pierduți




Figura 2: Rata de renunțare în funcție de țară și gen



Pentru a evalua corect diferențele demografice, a fost necesară convertirea numărului absolut de plecări în proporții (rate). Analizând datele procentuale, se observă că:

- **Geografie:** Deși majoritatea clienților băncii sunt situați în Franța, analiza proporțională arată că Germania înregistrează cea mai mare rată de pierdere a clienților (aprox. 32%), aproape dublu față de Franța și Spania.
- **Gen:** Din punct de vedere al genului, chiar dacă baza de date conține mai mulți bărbați, analizând frecvențele relative se observă o discrepanță clară: femeile au o probabilitate vizibil mai mare de a părăsi banca (aprox. 25% dintre femei au renunțat) comparativ cu bărbații (aprox. 16%).

Aceste perspective sugerează că banca ar trebui să investigheze probleme specifice legate de clienții din Germania și de segmentul feminin.

3. Analiza Vârstei și a Situației Financiare

Pentru a aprofunda factorii care influențează retenția, am analizat distribuția renunțărilor în funcție de vârsta clienților și soldul conturilor lor bancare.



- **Vârsta (Age):** Se observă o corelație puternică între vârstă și decizia de a părăsi banca. Rata de renunțare crește semnificativ odată cu înaintarea în vârstă, atingând un punct critic în segmentul clienților de 40-60 de ani, după care tinde să scadă din nou. Clienții tineri au o rată de retenție mult mai bună.
- **Soldul Contului (Balance):** Distribuția soldurilor arată o concentrare mare a clienților cu un sold egal cu 0. Analizând rata de pierdere pe tranșe de sold, se constată că clienții cu solduri moderate sunt cei mai stabili și loiali. În schimb, riscul de plecare este ridicat la ambele extreme: clienții cu zero în cont părăsesc banca frecvent (acest lucru indicând adesea conturi deja inactive sau abandonate), însă cel mai mare semnal de alarmă se înregistrează la clienții cu solduri foarte mari, unde rata de plecare atinge cote critice, o proporție uriașă dintre aceștia alegând să își închidă conturile

4. Analiza Comportamentală: Membri activi și Produse deținute




Figura 6: Distribuția clienților în funcție de activitate și numărul de produse deținute.

Analizând interacțiunea clienților cu banca, observăm două aspecte comportamentale majore:

- **Statutul de membru:** Calitatea de membru activ scade probabilitatea de plecare. Există un volum semnificativ de clienți inactivi care aleg să își închidă conturile, sugerând necesitatea unor campanii de reactivare.
- **Numărul de produse:** Majoritatea absolută a bazei de clienți utilizează doar 1 sau 2 produse. Totuși, graficul evidențiază un semnal de alarmă critic în privința clienților cu 3 sau 4 produse: deși aceștia reprezintă un volum foarte mic din totalul portofoliului, aproape toți aleg să părăsească banca. Acest comportament atipic sugerează posibile nemulțumiri majore legate de complexitatea gestionării pachetelor multiple, costuri ascunse sau o experiență slabă a utilizatorului atunci când se adaugă produse suplimentare.

Analiză Predictivă și Model de Regresie

Analiza predictivă are ca scop identificarea factorilor care influențează decizia clienților de a părăsi banca și estimarea probabilității de churn. Conform cerințelor de analiză, obiectivul principal este prognozarea comportamentului viitor pentru a informa deciziile strategice de retenție.

1. Alegerea și justificarea modelului predictiv

În acest set de date, variabila țintă (*Exited*) este de tip binar, unde valoarea 1 indică pierderea clientului, iar 0 indică retenția acestuia. Datorită acestei caracteristici, abordarea teoretică optimă și standard pentru predicție este un model de regresie logistică. Totuși, pentru a facilita implementarea operațională direct în instrumentul de vizualizare (Power BI) și pentru a asigura un nivel ridicat de interpretabilitate în mediul de business, a fost adoptată o metodă alternativă de tip *risk scoring*. Această metodă aproximează logica unei regresii logistice clasice și permite o clasificare rapidă și intuitivă a clienților.


2. Mecanismul de funcționare a modelului

Modelul predictiv de *risk scoring* funcționează prin evaluarea variabilelor cu impact major, identificate în analiza descriptivă (precum vârsta, nivelul de activitate sau numărul de produse), atribuindu-le ponderi (puncte de risc) specifice. Pentru a construi un scor de risc precis, modelul aplică penalizări clienților care întrunesc condițiile de risc. De exemplu:

- **Factorul geografic:** În urma validării statistice prin testul Chi-Pătrat, care a confirmat legătura strânsă dintre țară și intenția de plecare, modelul acordă **20 de puncte de risc** clienților din Germania.

- **Factorul de activitate:** Clienții care au statutul de membri inactivi primesc automat alte **20 de puncte de risc**. Prin cumularea acestor ponderi pentru fiecare individ în parte, modelul generează un scor final de risc.

3. Performanța și acuratețea predicțiilor



Evaluarea validității modelului arată o performanță robustă, atingând o **acuratețe (precizie) de 78%**. Această performanță excelentă se reflectă în capacitatea modelului de a segmenta și diferenția eficient baza de clienți în trei categorii principale de predicție:

- **High Risk (Risc Ridicat):** Modelul a izolat clienții cu probabilitate maximă de plecare, rata de churn pentru această grupă fiind de **61,19%**.
- **Medium Risk (Risc Mediu):** Categorie de atenție, unde rata de churn este de **19,11%**.
- **Low Risk (Risc Scăzut):** Clienții loiali, modelul indicând un risc minim de doar **8,20%**. Diferența majoră dintre rata de 61% a segmentului cu risc ridicat și cea de 8% a celui cu risc scăzut demonstrează o capacitate ridicată de discriminare a modelului, validându-l ca un instrument predictiv de încredere pentru deciziile de afaceri.

4. Limite și direcții viitoare

Deși modelul actual oferă un echilibru optim între simplitate tehnică și utilitate practică, reprezentând o alternativă adecvată pentru acest stadiu al proiectului, el rămâne o aproximare a regresiei logistice. Într-un cadru tehnologic mai avansat, implementarea unui model complet de regresie logistică sau a unor algoritmi de *Machine Learning* ar permite eliminarea sistemului fix de punctare în favoarea estimării matematice exacte a probabilităților de plecare (ex. 83,4% probabilitate de churn) pentru fiecare client. Acest pas ar oferi o rafinare suplimentară a predicțiilor pe termen lung.

Ipoteze Verificate

Aici am căutat să aflu dacă deosebirile observate în comportament erau ceva real sau doar o întâmplare.

1. **Ideea mea:** Locul unde stă clientul influențează decizia sa de a părăsi banca.
2. **Ce am făcut:** Am folosit testul Chi-Pătrat în Excel pentru a compara cum pleacă clienții din Franța, Germania și Spania.
3. **Ce înseamnă:** Modelul de risc creat a confirmat această idee, oferind 20 de puncte de risc clienților din Germania.

Pentru a determina dacă locul de unde provine clientul are un impact asupra deciziei de a părăsi banca, am formulat următoarele presupuneri:

- **Ipoteza nulă** (H_0): Nu există nicio legătură între țara de origine a clientului (Geografie) și plecarea acestuia (Părăsit). Orice discrepanță observată este datorată pur și simplu întâmplării.
- **Ipoteza alternativă** (H_1): Există o conexiune relevantă din punct de vedere statistic între regiunea geografică și părăsirea băncii, sugerând că anumiți clienți din anumite zone (Germania) sunt mai predispuși să plece.

Abordare și Realizare

S-a efectuat testarea în Excel, utilizând un tabel de contingență pentru a confrunta frecvențele reale cu cele teoretice. Acest calcul a avut la bază formula testului Chi-pătrat (χ^2):

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

=CHISQ.TEST(B4:C6, B11:C13)

TESTUL CHI-PATRAT	0
-------------------	---

Unde:

- O_i reprezintă Frecvențele Observate (datele reale din Pivot).

- Ei reprezintă Frecvențele Așteptate (cele calculate teoretic).

Calculul Valorilor Așteptate

S-a făcut un tabel în care s-a folosit următoarea formulă :

$$E = \frac{\text{Total Rnd} \times \text{Total Coloan}}{\text{Total General}}$$

	A	B	C	D
1				
2	Count of CustomerId Column Labels ▼			
3	Row Labels ▼	PLECAT	RAMAS	Grand Total
4	France	810	4204	5014
5	Germany	814	1695	2509
6	Spain	413	2064	2477
7	Grand Total	2037	7963	10000
8				
9				
10	row label	Plecat	Ramas	
11	France	1021.3518	3992.6	
12	Germany	511.0833	7963	
13	Spain	504.5649	7861.4	

Evaluarea Maturității Datelor

În prezent, banca a depășit faza de simplă raportare și a început să folosească datele pentru a anticipa viitorul. Totuși, pentru a trece la un nivel avansat, trebuie analizate următoarele aspecte:

- **Calitatea și volumul datelor:** Avem o bază de date de 10.000 de înregistrări, ceea ce oferă o relevanță statistică bună. Datele sunt complete, dar calitatea lor pe termen lung depinde de eliminarea erorilor umane și a valorilor lipsă. Trebuie să implementăm procese automate de „curățare” a datelor pentru a ne asigura că predicțiile rămân corecte.
- **Infrastructura tehnică și stocarea:** Trecerea de la analize statice la un model predictiv necesită o infrastructură mai modernă. Recomandăm migrarea către o soluție de stocare centralizată (Cloud), care să permită actualizarea datelor în timp real, nu doar prin exporturi periodice.
- **Practici de Management al Datelor:** Este necesară o colaborare mai bună între departamente. Datele nu trebuie să rămână blocate la IT; ele trebuie să fie accesibile (sub reguli stricte de securitate/GDPR) echipei de marketing pentru a putea acționa rapid asupra clienților cu risc de plecare.
- **Potențialul Analitic:** Faptul că am obținut deja un model cu o acuratețe de 78% demonstrează că banca are un potențial imens. Suntem pregătiți să trecem de la „ce se întâmplă” la strategii personalizate, bazate pe Machine Learning.

Sugestii de Acțiune (Bazate pe Date)

Pentru a reduce rata de plecare (churn) de 20,37%, propunem următoarele direcții:

Strategii Organizaționale:


- Analiza Pieței din Germania: Deoarece rata de plecare în Germania este de 32% (dublu față de medie), trebuie investigat dacă există probleme de competitivitate la nivel de preț sau dacă serviciile oferite acolo nu sunt adaptate specificului local.
- Pachete de loialitate pentru segmentul 40–60 de ani: Acești clienți reprezintă categoria cu cel mai mare risc. Sugerăm campanii de retenție care să pună accent pe stabilitate și pe beneficii pe termen lung (ex. bonusuri la depozite).
- Simplificarea ofertei Multi-Produs: clienții cu 3 sau 4 produse pleacă cel mai des. Aceasta indică o posibilă frustrare legată de complexitatea gestionării conturilor. Recomandăm simplificarea interfeței bancare pentru acești utilizatori.

Îmbunătățiri Tehnice:


- Sistem de Alertă Timpurie: cei 4.310 clienți identificați cu un scor de risc de peste 45 trebuie monitorizați în mod prioritar. Putem automatiza o notificare către echipa de vânzări atunci când un astfel de client atinge un prag critic.
- Campanii de Reactivare: Clienții inactivi primesc automat puncte de risc (+20). Trebuie implementate fluxuri de comunicare (e-mail/SMS) prin care să le oferim motive concrete pentru a reîncepe să folosească serviciile băncii.

Rezumat Executiv

Datele ne arată clar că plecările clienților urmează anumite tipare (vârstă, locație, număr de produse). Folosind modelul nostru care are o precizie de 78%, putem înceta să mai fim reactivi și să începem să salvăm clienții înainte ca aceștia să plece. O organizare mai bună a datelor și o atenție specială pieței din Germania sunt prioritățile zero pentru a proteja veniturile băncii.



Acest grafic prezintă distribuția clienților care au plecat sau au rămas clienți în funcție de țara de proveniență.



Iar acesta ne prezinta distribuția dintre categoria de vârstă și statutul de părăsire al bănci

Concluzii

În mediul bancar extrem de competitiv de astăzi, retenția clienților este esențială pentru menținerea profitabilității, deoarece costurile asociate cu atragerea de noi clienți sunt semnificativ mai mari decât cele necesare pentru loializarea celor existenți. Analiza de față demonstrează valoarea inestimabilă a adoptării unei abordări centrate pe date (data-driven decision-making) pentru asigurarea succesului pe termen lung.

Trecerea de la simpla constatare a unei rate de renunțare de 20,37% la înțelegerea cauzelor profunde ale acestora a fost posibilă doar prin explorarea analitică și modelarea predictivă a datelor. Datele ne-au scos la iveală vulnerabilități specifice pe care intuiția singură nu le-ar fi putut izola și prioritiza cu precizie: problemele de competitivitate pe piața din Germania, riscul critic de plecare în rândul segmentului de vârstă 40-60 de ani și frustrările aparente ale clienților care utilizează pachete complexe de 3 sau 4 produse.

Adevăratul succes al afacerii rezidă în transformarea acestor informații în acțiuni strategice și operaționale. Prin valorificarea modelului nostru predictiv, care a demonstrat o precizie de 78%, banca are acum oportunitatea de a evolua dintr-o organizație reactivă, care acționează abia după pierderea clientului, într-o organizație proactivă. Implementarea unui sistem de alertă timpurie pentru clienții cu risc ridicat și direcționarea eforturilor de marketing către campanii de reactivare bazate pe dovezi vor permite băncii să intervină salvator înainte ca intenția de plecare să se materializeze.

În concluzie, luarea deciziilor bazate pe date nu este doar un simplu exercițiu tehnic de raportare, ci un pilon fundamental pentru creșterea afacerii. O cultură organizațională care fundamentează strategiile pe dovezi statistice reușește să optimizeze costurile operaționale, să îmbunătățească experiența clienților și, în cele din urmă, să asigure o profitabilitate sustenabilă.